Licence MIAGE

Rapport de projet Graphes et OpenData

Apprentissage Fédéré pour la Prédiction des Maladies Cardiaques

Projet réalisé du 16 décembre 2025 au 10 mai 2026

Projet Réalisé Seul

Rafael Rodrigues — 43002619

Repository GitHub :
github.com/rdsrafa/Apprentissage_federe

Remerciements

Je tiens à remercier mon enseignant, Monsieur François Delbot, responsable du module *Graphes et OpenData*, pour ses conseils et sa disponibilité tout au long de ce projet. Ce travail m'a permis d'explorer concrètement l'intersection entre la théorie des graphes, l'apprentissage automatique distribué et les enjeux de protection des données personnelles dans le domaine médical.

De plus, la découverte d'un projet et la réalisation de celui-ci en autonomie m'ont permis d'explorer un univers que je ne connaissais pas, sans la confusion qui aurait pu apparaître dans un travail de groupe. Cependant, le travail en équipe permet d'échanger et de confronter des idées autour d'un sujet commun, ce qui m'a tout de même manqué.

Dans l'ensemble, j'ai beaucoup apprécié réaliser ce projet : il m'a permis de comprendre de manière concrète ce dont l'informatique est capable et comment elle peut être mise au service du bien collectif.

Table des matières

1 Introduction **5**
1.1 Qu'est-ce que l'apprentissage fédéré ? 5
1.2 Définition des données médicales sensibles 5
1.3 Ce que l'on fait dans ce projet 5
1.4 Hypothèse scientifique 5
1.5 Dataset utilisé 5

2 Environnement de travail **6**
2.1 Matériel 6
2.2 Logiciels 6
2.3 Organisation du code source 6

3 Description du projet et objectifs **7**
3.1 Pourquoi cette expérience ? 7
3.2 Principe de l'apprentissage fédéré 8
3.3 FedProx : gestion de l'hétérogénéité non-IID 8
3.4 Partitionnement non-IID par distribution de Dirichlet 8
3.5 Objectifs 9

4 Bibliothèques, Outils et Technologies **10**
4.1 PyTorch — Réseau de neurones 10
4.2 Flower — Infrastructure fédérée 10
4.3 NetworkX — Analyse graph-théorique 10
4.4 scikit-learn — Évaluation et prétraitement 10

5 Travail réalisé **12**
5.1 Ce que j'ai réalisé 12
5.2 Fonctionnalités réalisées 12
5.3 Résultats expérimentaux 13
5.4 Analyse graph-théorique du système 14
5.5 Conformité RGPD 14
5.6 Répartition du travail 15

6 Recherche personnelle et approfondissements **16**
6.1 L'apprentissage fédéré comme révolution du domaine médical 16
6.2 Un gain important : les maladies rares 16
6.3 Résultats concrets dans le monde réel 17
6.4 Limites identifiées de l'apprentissage fédéré 17
6.5 Pistes d'améliorations techniques 17

7 Difficultés rencontrées **19**
7.1 Gestion de la mémoire avec Ray/Flower simulation 19
7.2 Alignement du terme proximal FedProx 19
7.3 Centralité de degré sur graphe dirigé 19
7.4 Reproductibilité des expériences 19

8 Bilan **20**
8.1 Conclusion 20
8.2 Perspectives 21

9 Bibliographie **22**

10 Webographie **23**

11 Annexes **24**

A Exemple d'exécution du projet **24**

B Manuel utilisateur **27**

1 Introduction

1.1 Qu'est-ce que l'apprentissage fédéré ?

C'est un paradigme d'apprentissage automatique décentralisé où plusieurs appareils ou serveurs entraînent un modèle commun sans partager leurs données locales, garantissant ainsi la confidentialité et la sécurité des informations.

Le principe de l'apprentissage fédéré pourrait réellement révolutionner le domaine médical notamment concernant la prise en charge des différents clients et réussir à proposer les meilleures prises en charge grâce à la collaboration des médecins.

Il faut savoir que les données dans le milieu médical sont dites sensibles.

1.2 Définition des données médicales sensibles

Selon le RGPD, les données de santé sont des données à caractère personnel relatives à la santé physique ou mentale d'une personne, incluant les résultats médicaux, dossiers hospitaliers, données génétiques ou biométriques à finalité médicale, ainsi que les informations issues de dispositifs connectés ou d'essais cliniques. Elles sont considérées comme sensibles en raison de leur nature intime et de l'impact potentiel sur les droits et libertés des individus.

1.3 Ce que l'on fait dans ce projet

De notre côté, ce qu'on va faire c'est une simulation entre plusieurs hôpitaux qui vont entraîner de leur côté le modèle et ensuite tout mutualiser dans un serveur central.

Cet apprentissage permet de faire circuler un modèle d'apprentissage entre des hôpitaux, sans qu'il soit nécessaire d'échanger les données médicales relatives aux personnes. Ainsi les données de base vont rester dans leurs lieux d'origine ; aucune fuite, car le principe de base est d'éviter tout échange de données : on ne fait circuler que les paramètres de l'algorithme d'apprentissage.

Avec notre simulation on aura cinq modèles (un pour chaque hôpital) entraînés localement, puis les paramètres seront ensuite partagés et mutualisés dans un modèle global.

1.4 Hypothèse scientifique

L'hypothèse centrale est la suivante :

$$F1_{\text{local}} \ll F1_{\text{fédéré}} \approx F1_{\text{centralisé}} \tag{1}$$

L'écart entre le modèle fédéré et le modèle centralisé doit être inférieur à 5% pour valider l'hypothèse.

1.5 Dataset utilisé

Le projet repose sur le **Cleveland Heart Disease Dataset** [Det88], issu du dépôt UCI Machine Learning Repository. Il contient 303 entrées correspondant à des patients adultes, caractérisés par 13 attributs cliniques (âge, pression artérielle, cholestérol, fréquence cardiaque maximale, etc.) et un label binaire indiquant la présence ou l'absence d'une maladie cardiaque.

2 Environnement de travail

2.1 Matériel

Le projet a été développé et exécuté sur un ordinateur personnel dont les caractéristiques sont les suivantes :

Nom de l'appareil	LUFFY
Processeur	AMD Ryzen 5 7535U with Radeon Graphics (2,90 GHz)
Mémoire RAM	16,0 Go installés (13,7 Go utilisables)
Type de système	Système d'exploitation 64 bits, processeur x64

Table 1 – Configuration matérielle de la machine de développement

La simulation d'apprentissage fédéré a été exécutée entièrement sur CPU, sans recours à un GPU. Le Tableau 1 présente les caractéristiques retenues. Les 30 rounds de simulation FL s'exécutent en moins de deux minutes sur cette configuration, ce qui confirme que le projet est accessible sans infrastructure spécialisée.

2.2 Logiciels

Outil	**Version**	**Rôle dans le projet**
Python	3.10	Langage principal
PyTorch	2.2	Définition et entraînement du réseau de neurones
Flower (flwr)	1.8	Structure client/serveur pour le FL
scikit-learn	1.4	Métriques, normalisation, partitionnement
NetworkX	3.2	Modélisation du graphe de communication FL
Matplotlib	3.8	Courbes de convergence et figures
Seaborn	0.13	Heatmaps et matrices de confusion
NumPy / Pandas	1.26 / 2.1	Manipulation des données
Git / GitHub	—	Versionnement du code source

Table 2 – Environnement logiciel du projet

Toutes les dépendances (Tableau 2) s'installent en une commande :

```
pip install torch scikit-learn networkx matplotlib seaborn
   pandas numpy flwr
```

Listing 1 – Installation des dépendances

2.3 Organisation du code source

Le code est découpé en modules distincts, chacun avec une responsabilité unique :

```
federated_health/
    ├── config.py
    ├── heart.csv
    ├── main.py
    ├── README.md
    ├── data/
          │   └── dataset.py
    ├── federated/
          │   ├── client.py
          │   ├── serveur.py
          │   └── simulation.py
    ├── graph/
          │   └── network.py
    ├── model/
          │   └── network.py
    ├── visualization/
          │   └── plots.py
    └── results/
              ├── 01_data_distribution.png
              ├── 02_convergence_curves.png
              ├── 03_comparison_heatmap.png
              ├── 04_fl_graph.png
              ├── 05_confusion_matrices.png
              ├── 06_metric_evolution.png
              ├── 07_summary_dashboard.png
              └── results.json
```

Dossier
Fichier Python (.py)
Figure générée (.png)
Données (.csv / .json)
Documentation (.md)

FIGURE 1 – Architecture du projet federated_health

3 Description du projet et objectifs

3.1 Pourquoi cette expérience ?

Le problème de départ est simple : les hôpitaux ont chacun des données précieuses sur leurs patients, mais ils ne peuvent pas les partager entre eux pour des raisons légales et éthiques. Pourtant, un modèle entraîné sur les données d'un seul hôpital est souvent insuffisant — trop peu de données, des biais liés à la population locale, des classes déséquilibrées.

L'objectif de cette expérience est donc de répondre à la question suivante : est-il possible de faire collaborer plusieurs hôpitaux pour améliorer un modèle de prédiction de maladie cardiaque, sans qu'aucune donnée patient ne quitte son hôpital d'origine ? Et si oui, à quel prix en termes de performance par rapport à un modèle qui aurait accès à toutes les données ?

Pour répondre à cette question, on simule trois scénarios qui représentent trois

réalités différentes du monde médical :

— **Le scénario local** : chaque hôpital fait de son mieux tout seul, sans aucune collaboration. C'est la situation actuelle dans beaucoup d'établissements.
— **Le scénario centralisé** : tous les hôpitaux mettent leurs données en commun dans une base centrale. C'est la solution idéale en termes de performance, mais totalement impossible en pratique à cause du RGPD.
— **Le scénario fédéré** : les hôpitaux collaborent en partageant uniquement les paramètres de leur modèle, jamais les données. C'est ce qu'on cherche à valider dans ce projet.

3.2 Principe de l'apprentissage fédéré

L'apprentissage fédéré repose sur un protocole en quatre étapes, répété pendant T rounds de communication :

1. **Broadcast** : le serveur envoie les paramètres du modèle global $w^{(t)}$ à tous les hôpitaux.
2. **Entraînement local** : chaque hôpital k s'entraîne sur ses données privées $\mathcal{D}_k$ pendant E époques locales.
3. **Remontée** : les hôpitaux renvoient leurs paramètres mis à jour au serveur. Aucune donnée brute ne transite.
4. **Agrégation FedAvg** : le serveur calcule le nouveau modèle global :

$$w^{(t+1)} = \sum_{k=1}^{K} \frac{n_k}{N} \cdot w_k^{(t+1)} \tag{2}$$

où n_k est le nombre de patients à l'hôpital k et $N = \sum_k n_k$ le total. Les hôpitaux avec plus de données contribuent proportionnellement davantage.

3.3 FedProx : gestion de l'hétérogénéité non-IID

Le problème du non-IID en apprentissage fédéré est la violation de l'hypothèse d'homogénéité des distributions de données entre clients, ce qui induit un biais de gradient, une dérive des modèles locaux et une dégradation de la convergence et des performances globales.

Pour pallier ce problème, nous utilisons **FedProx** [Li20], qui ajoute un terme de régularisation proximal à la perte locale :

$$\mathcal{L}_k^{\text{FedProx}}(w) = \mathcal{L}_k(w) + \frac{\mu}{2} \left\| w - w^{(t)} \right\|^2 \tag{3}$$

Le terme $\frac{\mu}{2}\|w - w^{(t)}\|^2$ contraint chaque hôpital à ne pas trop s'éloigner du modèle global. Nous utilisons $\mu = 0{,}01$.

3.4 Partitionnement non-IID par distribution de Dirichlet

Pour simuler l'hétérogénéité réelle entre hôpitaux, nous utilisons un partitionnement par distribution de Dirichlet de paramètre $\alpha = 0{,}75$. Ce niveau correspond à une hétérogénéité modérée et réaliste : un hôpital H4 voit 88% de patients malades (service de cardiologie spécialisé), tandis que H3 n'en voit que 24% (cabinet généraliste).

3.5 Objectifs

1. Démontrer que le FL atteint des performances proches du centralisé.
2. Modéliser le système comme un graphe et prouver formellement la confidentialité via les métriques NetworkX.
3. Argumenter la conformité RGPD Articles 5, 25 et 83.
4. Produire un projet structuré, documenté et entièrement reproductible.

4 Bibliothèques, Outils et Technologies

4.1 PyTorch — Réseau de neurones

Pourquoi un réseau de neurones et pas une régression logistique ? La régression logistique est un classifieur linéaire : elle ne peut modéliser que des frontières de décision droites dans l'espace des features. Or les données médicales présentent des interactions non-linéaires complexes entre les features (par exemple, l'effet de l'âge combiné à la fréquence cardiaque maximale n'est pas simplement additif). Un réseau de neurones avec des couches cachées capture ces interactions non-linéaires.

De plus, et c'est la raison principale dans le contexte du FL : **les paramètres d'un réseau de neurones (poids et biais) peuvent être moyennés directement entre clients** via FedAvg, ce qui n'est pas le cas de tous les modèles. La régression logistique aurait pu fonctionner pour l'agrégation, mais elle n'aurait pas permis d'utiliser FedProx ni de bénéficier des BatchNorm et Dropout essentiels pour stabiliser l'entraînement sur des petits datasets hétérogènes comme ceux de nos hôpitaux simulés.

Architecture choisie. Le modèle utilisé est un Perceptron Multi-Couches (MLP) :

```
Input(13)
  -> Linear(64) -> BatchNorm -> ReLU -> Dropout(0.3)
  -> Linear(32) -> BatchNorm -> ReLU -> Dropout(0.2)
  -> Linear(16) -> ReLU
  -> Linear(2)  # classification binaire
```

Listing 2 – Architecture HeartDiseaseNet

- **BatchNorm** : stabilise l'entraînement sur des mini-batchs hétérogènes entre hôpitaux.
- **Dropout** : régularise pour éviter le surapprentissage sur de petits datasets locaux (H2 n'a que 25 patients).
- **3 762 paramètres** : suffisant pour capturer la complexité du problème sans surapprentissage sur 303 patients au total.

4.2 Flower — Infrastructure fédérée

D'abord j'ai implémenté FedAvg manuellement pour comprendre les mécanismes, puis j'ai utilisé Flower pour simuler un environnement fédéré réel.

Flower fournit les abstractions `NumPyClient` (côté hôpital) et `Strategy` (côté serveur). La boucle de simulation est implémentée manuellement (sans le moteur Ray) pour des raisons de contrôle et de lisibilité.

4.3 NetworkX — Analyse graph-théorique

NetworkX modélise le système FL comme un graphe dirigé `nx.DiGraph` et calcule automatiquement : centralité de degré, centralité d'intermédiarité, coefficient de clustering, diamètre et chemin moyen. Ces métriques fournissent une preuve formelle de la confidentialité structurelle.

4.4 scikit-learn — Évaluation et prétraitement

scikit-learn assure deux tâches :

— La normalisation des features par `StandardScaler`, fitté sur le train uniquement (pas de fuite vers le test).
— Le calcul des métriques : accuracy, précision, rappel et F1 pondérés.

5 Travail réalisé

5.1 Ce que j'ai réalisé

Voici de façon concrète l'ensemble de ce que j'ai mis en place dans ce projet :

— **Le chargement et la préparation des données** : lecture du dataset Cleveland, normalisation par StandardScaler fitté uniquement sur le train pour éviter toute fuite de données, et split stratifié 80/20.

— **Le partitionnement non-IID** : implémentation d'un partitionnement par distribution de Dirichlet avec garantie d'un minimum de samples par classe dans chaque hôpital, pour simuler de façon réaliste l'hétérogénéité entre établissements.

— **L'architecture du modèle** : conception d'un MLP avec BatchNorm et Dropout adapté aux données tabulaires médicales et compatible avec l'agrégation FedAvg.

— **Le client hôpital** : implémentation de la classe `HospitalClient` qui gère la réception des paramètres globaux, l'entraînement local avec le terme proximal FedProx, et la remontée des paramètres mis à jour.

— **Le serveur d'agrégation** : implémentation de la classe `FederatedServeur` qui orchestre chaque round : broadcast, collecte, agrégation FedAvg pondérée par la taille des datasets, et scheduling du learning rate.

— **La boucle de simulation complète** : implémentation manuelle de la boucle FL (sans Ray) avec les trois conditions expérimentales : fédéré, centralisé et local.

— **La modélisation graph-théorique** : construction du graphe dirigé avec NetworkX et calcul de toutes les métriques structurelles pertinentes pour l'analyse FL.

— **Les visualisations** : production de 7 figures publication-ready couvrant la distribution des données, la convergence, la comparaison des conditions, le graphe, les matrices de confusion et le tableau de bord de synthèse.

5.2 Fonctionnalités réalisées

Fonctionnalité	**Statut**
Chargement et prétraitement du dataset Cleveland	Réalisé
Partitionnement non-IID par distribution de Dirichlet	Réalisé
Architecture MLP avec BatchNorm et Dropout	Réalisé
Client hôpital FL (échange de paramètres)	Réalisé
Serveur d'agrégation FedAvg pondéré	Réalisé
Régularisation proximale FedProx ($\mu = 0{,}01$)	Réalisé
Baseline centralisé (borne supérieure)	Réalisé
Baselines locaux (5 hôpitaux en isolation)	Réalisé
Modélisation graph-théorique avec NetworkX	Réalisé
Calcul des métriques de graphe	Réalisé
7 visualisations publication-ready (PNG 200 dpi)	Réalisé
Sauvegarde des résultats en JSON Et visualisation POWER BI (Merci le Stage)	Réalisé

Table 3 – Fonctionnalités prévues et leur statut de réalisation

Comme le montre le Tableau 3, l'intégralité des objectifs a été atteinte sans exception.

5.3 Résultats expérimentaux

Trois conditions ont été comparées sur le même ensemble de test (61 patients, split stratifié 80/20, jamais vu pendant l'entraînement) :

Condition	**Accuracy**	**F1**	**Précision**	**Rappel**
Local H1 (67 patients, 58% malades)	0,7213	0,7195	0,7212	0,7213
Local H2 (25 patients, 72% malades)	0,6557	0,6477	0,6577	0,6557
Local H3 (54 patients, 24% malades)	0,7213	0,7163	0,7615	0,7213
Local H4 (50 patients, 88% malades)	0,6230	0,5889	0,6446	0,6230
Local H5 (46 patients, 39% malades)	0,7705	0,7701	0,7848	0,7705
Local (moyenne)	**0,698**	**0,6885**	—	—
Fédéré (FedProx)	**0,8197**	**0,8154**	**0,8346**	**0,8197**
Centralisé (borne sup.)	0,8525	0,8504	0,8604	0,8525

Table 4 – Comparaison des performances : Local vs Fédéré vs Centralisé

Lecture des résultats. Le premier constat que l'on peut faire en lisant le Tableau 4 est l'écart important entre les hôpitaux locaux. H4, qui n'a que 50 patients dont 88% malades, obtient un F1 de seulement 0,5889 : son modèle est tellement biaisé vers la classe positive qu'il est peu fiable en pratique. À l'inverse, H5 avec une distribution plus équilibrée atteint 0,7701. Cet écart illustre exactement le problème du non-IID : chaque hôpital seul ne voit qu'une partie de la réalité.

Le modèle fédéré, lui, atteint un F1 de **0,8154**, soit un gain de **+12,69%** par rapport à la moyenne locale. Ce gain n'est pas dû à un partage de données — c'est uniquement l'effet de la mutualisation des paramètres. Chaque hôpital bénéficie de ce que les autres ont appris sur leurs propres patients.

L'écart avec le modèle centralisé est de **3,50%**, ce qui valide l'hypothèse formulée en équation (1). On perd moins de 4 points de F1 en échange d'une confidentialité totale des données.

Lecture des courbes de convergence. La Figure 2 montre plusieurs choses importantes. D'abord, au round 1, le modèle fédéré part d'un F1 de 0,65 environ car le modèle global est encore aléatoire. Dès le round 5, il dépasse déjà la moyenne des modèles locaux, ce qui prouve que la collaboration apporte rapidement de la valeur. La convergence se stabilise autour du round 10 et reste stable jusqu'au round 30, sans oscillations ni divergence. La courbe de loss (droite) confirme cette stabilité : elle décroît régulièrement sans signe de surapprentissage.

Lecture de la heatmap de comparaison. La heatmap de la Figure 3 permet de lire d'un seul coup d'œil l'ensemble des performances. On voit clairement que la ligne du modèle fédéré est visuellement très proche de celle du centralisé, avec des valeurs en vert foncé sur toutes les métriques. À l'inverse, H4 ressort en rouge sur le F1, ce qui confirme que son isolement lui est fortement préjudiciable.

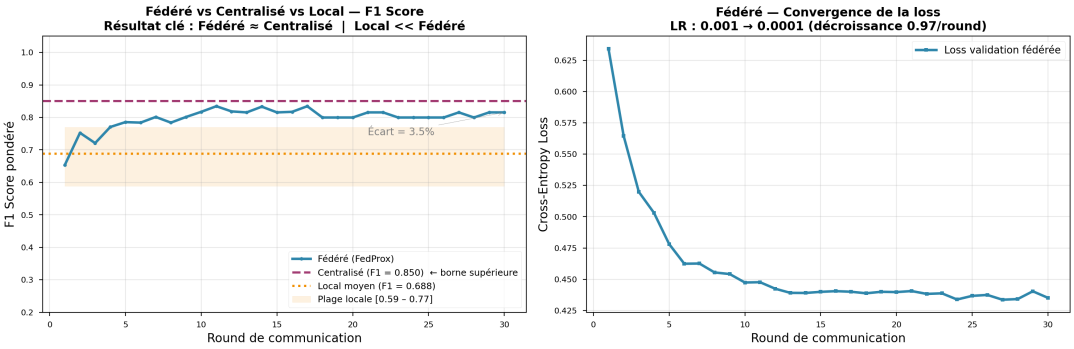

FIGURE 2 – Courbes de convergence : F1-score (gauche) et loss de validation (droite) au fil des 30 rounds de communication. La ligne pointillée rouge représente le modèle centralisé (borne supérieure). La ligne pointillée orange représente la moyenne des modèles locaux. La zone ombrée représente la plage complète des performances locales (du pire hôpital au meilleur).

5.4 Analyse graph-théorique du système

La Figure 4 présente trois informations complémentaires. Le graphe de gauche montre visuellement que les hôpitaux ne sont jamais connectés directement entre eux : tout passe par le serveur. C'est cette topologie étoile qui garantit l'isolation des données.

Le graphique central de centralité confirme cette intuition de façon formelle : le serveur obtient une centralité de degré de 1,0 (le maximum possible), tandis que chaque hôpital n'obtient que 0,2. Cela signifie que le serveur est connecté à tous les nœuds du réseau, et qu'aucun hôpital ne l'est à un autre.

Métrique	**Valeur**	**Ce que ça prouve**
Centralité de degré (Serveur)	1,0000	Hub unique, topologie étoile
Centralité d'intermédiarité (Serveur)	1,0000	100% des chemins inter-hôpitaux passent par le serveur
Coefficient de clustering moyen	0,0000	Aucun lien direct entre hôpitaux
Densité du graphe	0,3333	Design minimaliste (10 arêtes / 30 possibles)
Diamètre	2	Max 2 sauts entre deux hôpitaux quelconques

TABLE 5 – Métriques graph-théoriques du système FL et leur interprétation

Le coefficient de clustering nul dans le Tableau 5 est la métrique la plus importante d'un point de vue confidentialité. Un coefficient de clustering nul signifie qu'aucun trio de nœuds ne forme un triangle dans le graphe — autrement dit, si H1 et H2 sont tous les deux connectés au serveur, ils ne sont pas connectés entre eux. Il n'existe aucun chemin direct entre deux hôpitaux, ce qui rend toute fuite de données structurellement impossible.

5.5 Conformité RGPD

Le Tableau 6 résume comment le système satisfait les principaux articles du RGPD. L'article 25 est le plus intéressant dans notre cas : la *protection dès la conception* (Privacy by Design) n'est pas une politique que l'on ajoute après coup, mais une propriété

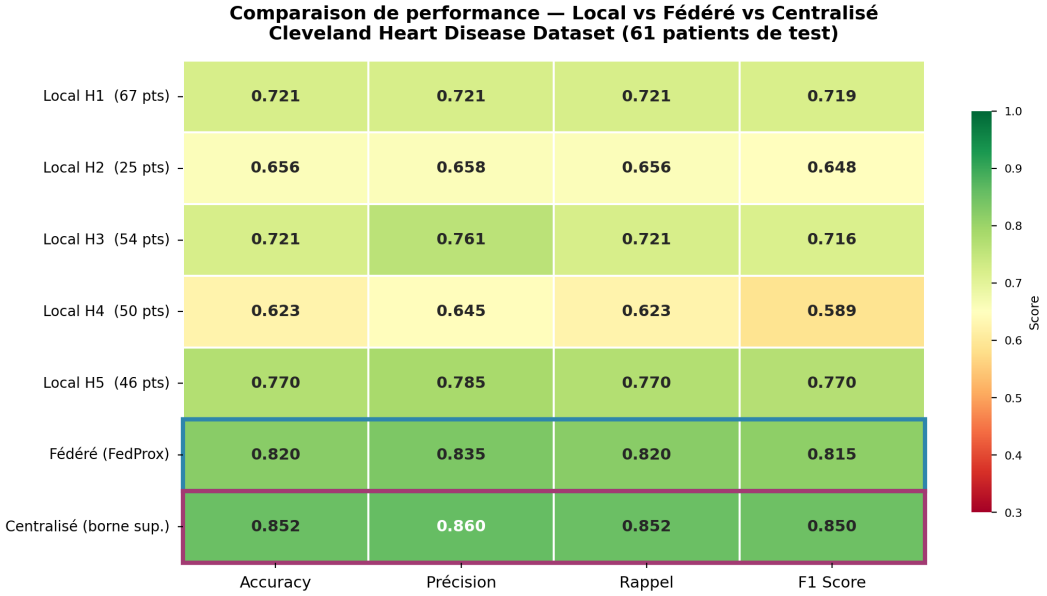

FIGURE 3 – Heatmap des performances : chaque ligne est une condition (hôpital local, fédéré ou centralisé), chaque colonne est une métrique. Le rouge indique les performances faibles, le vert les performances élevées. Les bordures colorées mettent en évidence les lignes fédérée (bleu) et centralisée (violet).

Article	Principe	Comment le FL le satisfait
Art. 5(1)(c)	Minimisation des données	Seuls les poids du modèle transitent
Art. 17	Droit à l'effacement	Aucune donnée patient hors de l'hôpital
Art. 25	Protection dès la conception	Topologie étoile = isolation structurelle
Art. 83	Responsabilité	Pas de risque de violation centralisée

TABLE 6 – Conformité du système FL aux articles du RGPD

topologique du système, prouvée formellement par le coefficient de clustering nul.

5.6 Répartition du travail

Ce projet a été réalisé individuellement par Rafael Rodrigues (43002619). L'ensemble du code, de la modélisation et de la rédaction a été produit par un seul auteur.

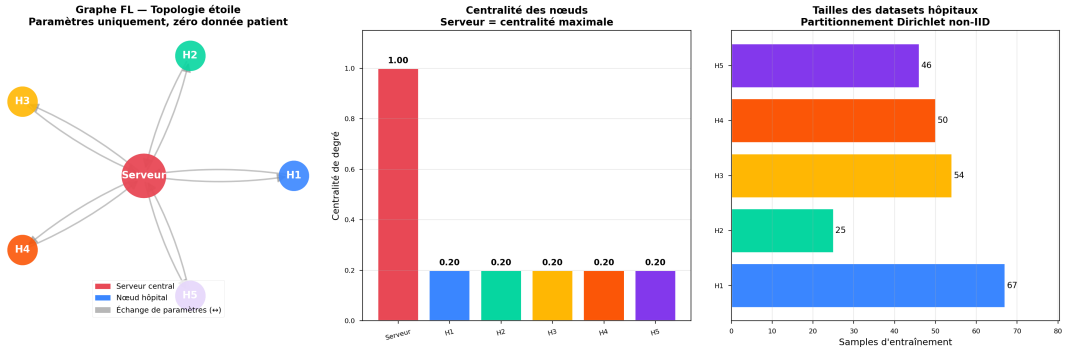

FIGURE 4 – Analyse graph-théorique du système FL. *Gauche* : topologie étoile — le serveur est au centre, les hôpitaux sur la périphérie, les flèches représentent les flux de paramètres (jamais de données brutes). *Centre* : centralité de degré de chaque nœud — le serveur obtient 1,0 (maximum absolu), les hôpitaux 0,2. *Droite* : nombre de patients par hôpital, illustrant l'hétérogénéité du partitionnement Dirichlet.

6 Recherche personnelle et approfondissements

Cette section regroupe mes recherches personnelles menées en parallèle du développement technique, ainsi que les pistes d'amélioration que j'ai identifiées. Ces réflexions constituent une base de travail pour une éventuelle poursuite du projet.

6.1 L'apprentissage fédéré comme révolution du domaine médical

L'apprentissage fédéré en recherche sur le cancer définit la collaboration entre institutions, tout en préservant la confidentialité des données des patients. L'apprentissage fédéré offre une solution novatrice. Plutôt que de centraliser les données dans un référentiel unique, l'apprentissage fédéré en cancérologie permet à chaque centre de s'entraîner localement et de contribuer à l'amélioration d'un modèle global.

La méthode de l'apprentissage fédéré offre plusieurs avantages :

— **Sécurité des données** : les données sensibles des patients ne quittent jamais le site d'origine.
— **Évolutivité** : plusieurs institutions peuvent contribuer sans restrictions de transfert de données.
— **Robustesse du modèle** : l'entraînement sur des ensembles de données diversifiés améliore la généralisation.

On peut voir des exemples actuels de l'apprentissage fédéré dans la recherche sur le cancer :

— Modélisation des résultats de la radiothérapie
— Histopathologie et segmentation tumorale
— Diagnostic des cancers du sein, de la prostate et du poumon
— Génomique et données multimodales

6.2 Un gain important : les maladies rares

Un des gains importants de l'apprentissage porte sur les maladies rares : on ne peut pas vraiment faire du machine learning sur les cancers rares car on n'a pas assez de données sans le FL.

C'est un verrou majeur que l'apprentissage fédéré est en mesure de débloquer : en agrégeant les rares cas disponibles dans chaque hôpital sans les centraliser, il devient possible de construire des modèles là où aucun dataset individuel ne serait suffisant.

6.3 Résultats concrets dans le monde réel

Grâce à l'utilisation de technologies telles que l'intelligence artificielle (IA), via laquelle des modèles d'apprentissage automatique (ML) apprennent à prendre des décisions sur la base de modèles trouvés dans de grands ensembles de données sur les patients, cela a permis d'améliorer la précision des diagnostics médicaux et d'accélérer la recherche et le développement de médicaments indispensables.

Cependant, ces dernières années, les experts ont réalisé que le processus traditionnel de développement d'applications d'apprentissage automatique par la collecte centralisée de données est insuffisant, car les modèles ML efficaces pour les soins de santé nécessitent plus de données que celles qui seraient librement partagées, en raison de problèmes de sécurité et de confidentialité. Ces difficultés ont empêché l'IA de faire passer le secteur des soins de santé au niveau supérieur, où les modèles qui atteignent une précision de niveau clinique ne peuvent être dérivés que d'ensembles de données suffisamment vastes, diversifiés et conservés.

Pour démocratiser l'IA et tirer profit des données dans le secteur de la santé, il est nécessaire de disposer d'une méthode d'entraînement pour les modèles ML qui ne soit pas soumise aux risques de partage de données sensibles en dehors de l'institution qui les détient. L'apprentissage fédéré fournit une telle méthode.

Depuis 2020, Intel et l'Université de Pennsylvanie ont mené la plus grande étude d'apprentissage fédéré du secteur médical. Avec des ensembles de données provenant de 71 institutions sur six continents, l'étude a démontré sa capacité à améliorer de 33% la détection des tumeurs cérébrales [Int22].

6.4 Limites identifiées de l'apprentissage fédéré

Cependant il reste des limites auxquelles l'apprentissage fédéré se heurte :
— Hétérogénéité des données et distributions non-IID
— Charge d'étiquetage et d'annotation limitée
— Confidentialité, sécurité et fuite de modèles
— Gouvernance et confiance
— Infrastructure et évolutivité
— Acculturation des hôpitaux
— Collecte et harmonisation des données

Parmi ces obstacles, convaincre les acteurs reste l'un des défis les plus difficiles à surmonter : au-delà de la technique, c'est une question de confiance et de culture institutionnelle.

6.5 Pistes d'améliorations techniques

Modèles fédérés multimodaux. Mettre en place l'intégration de données radiologiques, pathologiques, etc. afin de créer des modèles prédictifs performants et de survie.

Confidentialité différentielle. Niveau sécurité : comme on a dit, on a que le partage des paramètres des données, cependant cette manière de traiter les données devra

prouver que les données y sont bien protégées de toute attaque. L'ajout d'un bruit gaussien calibré sur les gradients renforcerait la protection contre les attaques par inversion de gradients [Dwo14].

Extension vers d'autres pathologies. Est-ce que exploiter le modèle de l'apprentissage fédéré peut vraiment améliorer les chances de survie des patients atteints de cancer même rare ? En poussant l'analyse sur l'apprentissage fédéré, on pourrait à long terme trouver des solutions concrètes dans la recherche sur le cancer.

Topologies de graphes alternatives. Passer d'une topologie étoile à un graphe pair-à-pair (anneau, grille, aléatoire) modifierait les métriques de centralité et le comportement de convergence, ouvrant une analyse graph-théorique comparative intéressante.

Perspective de thèse. S'intéresser à Flower pour une amélioration en vue de faire une thèse. Le projet MOJAIC (spatial transcriptomics — Jean Ogier du Terrail) constitue une référence directe dans ce sens.

7 Difficultés rencontrées

7.1 Gestion de la mémoire avec Ray/Flower simulation

L'utilisation de `fl.simulation.start_simulation()` provoquait un dépassement de la limite mémoire (4 Go). La solution adoptée a été d'implémenter une boucle FL personnalisée sans Ray, en conservant la structure client/serveur de Flower mais en pilotant manuellement chaque round. Cette approche rend le code plus lisible et pédagogique.

7.2 Alignement du terme proximal FedProx

Le dictionnaire d'état PyTorch (`state_dict`) contient à la fois des paramètres apprenables et des buffers non-apprenables (BatchNorm). Appliquer le terme proximal sur l'ensemble causait une erreur de dimension. La correction a consisté à filtrer les paramètres via `named_parameters()`.

7.3 Centralité de degré sur graphe dirigé

NetworkX calcule par défaut la centralité sur les degrés entrant + sortant, donnant 2,0 au lieu de 1,0 pour le serveur. La correction : calculer la centralité sur le graphe non-dirigé `U = G.to_undirected()`.

7.4 Reproductibilité des expériences

Les graines aléatoires (`torch.manual_seed`, `np.random.seed`) doivent être fixées avant la construction du dataset et des partitions. Un seed fixé après la création du dataset ne garantit pas la reproductibilité du partitionnement Dirichlet.

8 Bilan

8.1 Conclusion

Ce projet démontre que l'apprentissage fédéré permet une collaboration efficace entre établissements médicaux sans compromettre la confidentialité des données des patients, tout en atteignant des performances proches de l'apprentissage centralisé, à condition d'utiliser des algorithmes adaptés à la non-IIDité des données.

```
============================================================
RAPPORT FINAL — VALIDATION DE L'HYPOTHÈSE
============================================================

  Condition                | Accuracy | F1 Score | Précision | Rappel
  ------------------------------------------------------------------------
  Local H1 ( 67 patients)   |   0.7213 | 0.7195   | 0.7212    | 0.7213
  Local H2 ( 25 patients)   |   0.6557 | 0.6477   | 0.6577    | 0.6557
  Local H3 ( 54 patients)   |   0.7213 | 0.7163   | 0.7615    | 0.7213
  Local H4 ( 50 patients)   |   0.6230 | 0.5889   | 0.6446    | 0.6230
  Local H5 ( 46 patients)   |   0.7705 | 0.7701   | 0.7848    | 0.7705
  ------------------------------------------------------------------------
  ★ Fédéré (FedProx)      |   0.8197 | 0.8154   | 0.8346    | 0.8197
  ▲ Centralisé (borne)    |   0.8525 | 0.8504   | 0.8604    | 0.8525

  Local (F1 moyen) :  0.6885
  Local (plage)    :  [0.5889 — 0.7701]
  Fédéré F1        :  0.8154
  Centralisé F1    :  0.8504

  Écart  (Fédéré — Centralisé) : 3.50%
  Gain   (Fédéré — Local moy.) : +12.69%

  ------------------------------------------------------------

 Hypothèse validée car l'écart = 3.50% < seuil de 5% :
  Le FL atteint 3.50% de moins que le centralisé
  tout en gagnant +12.69% vs les modèles locaux,
  avec ZÉRO donnée patient partagée entre hôpitaux.

============================================================

  Tous les outputs dans : results/
```

En chiffres :

Écart Fédéré – Centralisé : 3,50% $<$ 5% $\Rightarrow$ hypothèse validée

Gain vs Local moyen : +12,69%

Zéro donnée patient partagée entre hôpitaux

La double approche — performance empirique et preuve graph-théorique — constitue la valeur ajoutée principale de ce projet. On peut voir que le modèle de l'apprentissage fédéré arrive a s'adapter et au fil des rounds il devient de plus en plus précis pour atteindre un niveau très approché du résultat centralisé.

Voici le rapport Power BI que j'ai pu réalisé avec les données de résultat enregistrer en format json, notamment grâce a mon expérience de stage : Voir le rapport Power BI

8.2 Perspectives

1. **Confidentialité différentielle** : ajout d'un bruit gaussien sur les gradients pour résister aux attaques par inversion.
2. **Modèles multimodaux** : intégration de données radiologiques et pathologiques pour des modèles de survie plus complets.
3. **Maladies rares** : application du FL là où aucun dataset individuel n'est suffisant — le gain le plus important à long terme.
4. **Topologies alternatives** : graphes pair-à-pair pour une analyse comparative des métriques de centralité et de convergence.
5. **Déploiement réel** : simulation sur machines virtuelles distinctes avec Flower en mode distribué pour mesurer l'overhead réseau réel.

9 Bibliographie

[McM17] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. A. y Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data*, Proceedings of AISTATS, 2017.

[Li20] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Smola, V. Smith, *Federated Optimization in Heterogeneous Networks*, Proceedings of Machine Learning and Systems (MLSys), 2020.

[Kon16] J. Konečný et al., *Federated Learning : Strategies for Improving Communication Efficiency*, NIPS Workshop on Private Multi-Party Machine Learning, 2016.

[Dwo14] C. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy*, Foundations and Trends in Theoretical Computer Science, 9(3-4), 2014.

[Det88] R. Detrano et al., *International application of a new probability algorithm for the diagnosis of coronary artery disease*, The American Journal of Cardiology, 64(5), 1989.

[Int22] C. Pati et al. (Intel / University of Pennsylvania), *The federated tumor segmentation (FeTS) challenge*, arXiv :2105.05874, 2021.

10 Webographie

[MND] *L'apprentissage fédéré, le futur de la médecine basée sur les données*, https://www.mind.eu.com/health/article/lapprentissage-federe-le-futur-de-la-medecine-basee-sur-les-donnees/

[FLW] *Flower — A Friendly Federated Learning Framework*, https://flower.dev

[UCI] *UCI Machine Learning Repository — Heart Disease Dataset*, https://archive.ics.uci.edu/ml/datasets/Heart+Disease

[PTH] *PyTorch — Documentation officielle*, https://pytorch.org/docs

[NXK] *NetworkX — Documentation officielle*, https://networkx.org/documentation

[RGPD] *Règlement (UE) 2016/679 — RGPD*, https://eur-lex.europa.eu/legal-content/FR/TXT/?uri=CELEX%3A32016R0679

[GIT] *Code source du projet — GitHub*, https://github.com/rdsrafa/Apprentissage_federe

[GH2] *Introduction to Federated Learning with Flower*, https://github.com/gehmit/AAFAAM/blob/master/Semaine1/Lundi/Flower_1_Intro_to_FL_PyTorch.ipynb

[AIS] *AI Summary Hub — Federated Learning*, https://emersonbraun.github.io/ai-summary-hub/fr/docs/federated-learning/

[AFS] *Apprentissage fédéré pour l'IA collaborative dans le secteur de la santé* https://droit.cairn.info/revue-internationale-de-droit-economique-2022-3-page-95?lang=fr

[DSS] *L'apprentissage fédéré, la clé pour développer des solutions de santé plus intelligentes* Cliquez ici pour voir l'article

[FLB] *FLamby : Datasets and Benchmarks for Cross-Silo Federated Learning in Realistic Healthcare Settings (j'ai traduit l'article j'ai pas encore ce niveau d'anglais)* https://openreview.net/pdf?id=GgM5DiAb6A2

11 Annexes

Annexe A : Exemple d'exécution du projet

Cette annexe présente une exécution complète du projet étape par étape, avec une capture d'écran illustrant chaque phase de la simulation.

Étape 1 — Chargement du dataset et création des partitions hôpitaux.

On va charger les données. De plus, on met en place au partitionnement des données pour les dispersés dans les 5 hopitaux, sachant que notre dataset ne compote pas énormemenet de patient on va faire en sorte qu'il y ai au minimum 1 malade et 1 sain dans chaque hopitaux grace au coefficent Dirichlet de 0.75

```
➜  federated_health python3 main.py
  FEDERATED LEARNING - PRÉDICTION MALADIE CARDIAQUE

  Cleveland Dataset | PyTorch + FedProx | 5 Hôpitaux

[1/7] Chargement du dataset & création des partitions hôpitaux...
[HeartDataset] 303 patients chargés - 242 train | 61 test
[HeartDataset] Features: 13 | Classes: 2
[HeartDataset] Équilibre - Pas de maladie: 138 | Maladie cardiaque: 165

[Partitionnement] Dirichlet α=0.75 - 5 hôpitaux
  H1:  67 patients | Sains:  28 | Malades:  39
  H2:  25 patients | Sains:   7 | Malades:  18
  H3:  54 patients | Sains:  41 | Malades:  13
  H4:  50 patients | Sains:   6 | Malades:  44
  H5:  46 patients | Sains:  28 | Malades:  18
```

Étape 2 — Modéliser le graphe en étoile de l'apprentissage fédéré

On a un graphe en étoile avec au centre le serveur central qui va entrainé l'ensemble des paramètres envoyés par les hoptiaux et les autre sommets représentes les hopitaux

```
[2/7] Modélisation du système fédéré comme un graphe...

============================================================
MÉTRIQUES DU GRAPHE — ANALYSE DU SYSTÈME FÉDÉRÉ
============================================================

  [Centralité] Centralité de degré du Serveur = 1.0000 (max = 1.0)
    → Le serveur est le seul hub de communication (topologie étoile).
      Aucun hôpital n'est connecté à un autre hôpital.
      L'isolation des données est garantie par la structure du graphe.

  [Densité] Densité du graphe = 0.3333
    → 10 arêtes sur 30 possibles (graphe complet).
      Design minimaliste : uniquement des liens serveur-hôpital.
      Supprimer le serveur déconnecte le graphe entier.

  [Clustering] Coefficient de clustering moyen = 0.0000
    → Quasi-zéro : les hôpitaux ne forment AUCUN triangle.
      Pas de lien pair-à-pair → aucun canal d'inférence entre hôpitaux.
      Satisfait l'Article 25 RGPD (Privacy by Design).

  [Chemins] Chemin moyen = 1.6667
    Diamètre = 2
    → Deux hôpitaux quelconques sont à exactement 2 sauts (via Serveur).
      Complexité de communication O(n), pas O(n²).
      Efficace et scalable à mesure que n_hôpitaux augmente.

  [Intermédiarité] Centralité d'intermédiarité du Serveur = 1.0000
    → Tout chemin inter-hôpital passe par le serveur.
      Unique point de confiance — cohérent avec le modèle de
      menace FL (serveur honnête-mais-curieux).
```

Étape 3 — Entrainement centralisé

Cette entrainement va nous servir a la fin pour comparer les deux modèles et voir si l'apprentissage fédéré peut etre utilisé avec un niveau de précision proche du modèle centralisé qui lui est totalement non conforme au RGPD

```
[3/7] Baseline centralisé (borne supérieure)...

============================================================
ENTRAÎNEMENT CENTRALISÉ  (borne supérieure — non conforme RGPD)
============================================================
  Accuracy:  0.8525
  F1 Score:  0.8504
  Précision: 0.8604
  Rappel:    0.8525
```

Étape 4 — Entrainements locaux

Les hopitaux vont chacun entrainer leurs données en locale sans collaboration pour préparer l'envoie des paramètres au serveur général

```
[4/7] Baselines locaux (isolation, aucune collaboration)...

============================================================
ENTRAÎNEMENT LOCAL  (baseline isolation - aucune collaboration)
============================================================
  H1 ( 67 patients, 58% malades) → Acc: 0.7213 | F1: 0.7195
  H2 ( 25 patients, 72% malades) → Acc: 0.6557 | F1: 0.6477
  H3 ( 54 patients, 24% malades) → Acc: 0.7213 | F1: 0.7163
  H4 ( 50 patients, 88% malades) → Acc: 0.6230 | F1: 0.5889
  H5 ( 46 patients, 39% malades) → Acc: 0.7705 | F1: 0.7701
```

Étape 5 — Simulation Apprentissage fédéré

Simulation de l'apprentissage fédéré en nombre de rounds auquel le modèle va tourner, on remarque une réel amélioration de rounds en rounds ce qui montre que la collaboration est beaucoup plus éfficace que le simple entrainement locale des données pour les hopitaux

```
[5/7] Simulation fédérée (FedProx)...

============================================================
APPRENTISSAGE FÉDÉRÉ  (FedProx, topologie étoile)
============================================================
[Serveur] Modèle global initialisé (3,762 paramètres)
  Round 01/30 | Acc: 0.6557 | F1: 0.6535 | Loss: 0.6342 | lr: 0.00097
  Round 05/30 | Acc: 0.7869 | F1: 0.7855 | Loss: 0.4782 | lr: 0.00086
  Round 10/30 | Acc: 0.8197 | F1: 0.8172 | Loss: 0.4474 | lr: 0.00074
  Round 15/30 | Acc: 0.8197 | F1: 0.8154 | Loss: 0.4400 | lr: 0.00063
  Round 20/30 | Acc: 0.8033 | F1: 0.7997 | Loss: 0.4398 | lr: 0.00054
  Round 25/30 | Acc: 0.8033 | F1: 0.7997 | Loss: 0.4367 | lr: 0.00047
  Round 30/30 | Acc: 0.8197 | F1: 0.8154 | Loss: 0.4352 | lr: 0.00040

  [Round Final 30]
  Accuracy  : 0.8197
  F1        : 0.8154
  Precision : 0.8346
  Recall    : 0.8197
```

Étape 6 — 7 Enregistrement des résultats

Ici, j'ai décider de sauvegarder les différents graphiques que j'ai pu réaliser pour visualiser les évolutions du au modèle d'apprentissage fédéré

```
[6/7] Génération des visualisations...
  Sauvegardé : results/01_data_distribution.png
  Sauvegardé : results/02_convergence_curves.png
  Sauvegardé : results/03_comparison_heatmap.png
  Sauvegardé : results/04_fl_graph.png
  Sauvegardé : results/05_confusion_matrices.png
  Sauvegardé : results/06_metric_evolution.png
  Sauvegardé : results/07_summary_dashboard.png

[7/7] Sauvegarde des résultats...
  Sauvegardé : results/results.json
```

Annexe B : Manuel utilisateur

Prérequis

```
pip install torch scikit-learn networkx matplotlib seaborn
   pandas numpy flwr
```

Lancement

```
cd federated_health/
python3 main.py
```

Paramétrage via config.py

Paramètre	Défaut	Effet
`NUM_ROUNDS`	30	Nombre de rounds de communication
`NUM_HOSPITALS`	5	Nombre d'hôpitaux simulés
`LOCAL_EPOCHS`	5	Époques locales par round
`DIRICHLET_ALPHA`	0,75	Hétérogénéité (plus faible = plus hétérogène)
`PROXIMAL_MU`	0,01	Force de la régularisation FedProx
`LEARNING_RATE`	0,001	Learning rate initial

Table 7 – Hyperparamètres configurables dans `config.py`

Voir le dépot README.md sur github pour plus de détails.